Alucinaciones en los grandes modelos de lenguaje y los límites de RAG

¿Hasta qué punto RAG mitiga realmente las alucinaciones de los LLM y cuáles son sus límites como mecanismo de confiabilidad?

Adri Martínez · Johan Guzmán

Universidad ICESI · Octubre de 2026

FICHA DE VERIFICACIÓN

Expediente ilustrativo · Folio 001

1. **Afirmación**
   El LLM produce un enunciado plausible
2. **Evidencia recuperada**
   RAG aporta documentos del corpus
3. **Contraste documental**
   ¿El texto respalda el enunciado?
4. **Verificación**
   Soporte comprobado afirmación por afirmación
5. **Decisión**
   Confiar, abstenerse o escalar a revisión

PENDIENTE DE VERIFICACIÓN

Sellos y fichas: recursos gráficos ilustrativos, no resultados.

Una respuesta fluida no es una respuesta verificada

Un problema de uso real

Los LLM ya funcionan como asistentes de búsqueda, redacción y apoyo a decisiones, y producen afirmaciones que suenan correctas pero son falsas o no verificables.

El ámbito jurídico lo hizo visible

Se documentaron sanciones a abogados que presentaron casos inexistentes generados por ChatGPT: el punto de partida de Magesh et al. (2025).

La respuesta de la industria: RAG

Responder «a libro abierto», apoyado en documentos recuperados, debería inventar menos (Lewis et al., 2020).

DECLARACIONES DE PROVEEDORES (RECOGIDAS POR MAGESH ET AL., 2025)

RAG «elimina» o «evita» las alucinaciones; citas «libres de alucinaciones».

A VERIFICAR

PREGUNTA DE INVESTIGACIÓN

¿Hasta qué punto RAG realmente mitiga las alucinaciones de los LLM y cuáles son sus límites como mecanismo de confiabilidad?

«Hasta qué punto» exige una respuesta graduada.

- **SP1** **Mecanismo.** ¿Qué cambia, en términos probabilísticos, al condicionar en documentos recuperados? ¿Qué no cambia?
- **SP2** **Localización del error.** ¿En qué etapas puede originarse una afirmación no respaldada aun con recuperación?
- **SP3** **Evidencia.** ¿Qué muestran los estudios sobre la reducción de alucinaciones y los errores que persisten?
- **SP4** **Medición.** ¿Cómo se mide una alucinación con recuperación y qué dimensiones deben separarse?
- **SP5** **Alternativas.** ¿Qué técnicas posteriores atacan los fallos residuales, y con qué costo?

RAG reduce el riesgo de alucinar; no garantiza veracidad

TESIS

RAG es un mecanismo de reducción de riesgo, no una garantía de veracidad.

Reduce las alucinaciones por ausencia o desactualización del conocimiento paramétrico, porque pone evidencia externa a disposición del generador.

Pero solo modifica la distribución condicional de la que se genera la respuesta: no obliga a que cada afirmación esté implicada por la evidencia.

H1

La recuperación reduce la alucinación frente a un modelo sin recuperación, cuando la evidencia pertinente existe en el corpus y se recupera.

H2

Aun con recuperación, una fracción no despreciable de respuestas contiene afirmaciones no respaldadas por el contexto o atribuciones incorrectas.

H3

El error residual no tiene una sola causa: se distribuye entre recuperación, uso del contexto, generación y atribución.

H4

La evaluación de la evidencia y la verificación de afirmaciones reducen errores adicionales, a costa de complejidad, latencia o dependencia del modelo.

Alucinar es afirmar con apariencia de seguridad lo que nada respalda

MAYNEZ ET AL. (2020)

Resúmenes abstractivos

Intrínseca: el texto contradice o tergiversa la fuente.
Extrínseca: añade información que no puede verificarse desde la fuente.

Ji et al. (2023) lo generalizan: contenido sin sentido o no fiel a la fuente.

HUANG ET AL. (2025)

LLM de propósito general

Factualidad: contradice hechos verificables del mundo o los fabrica.
Fidelidad: se aparta de las instrucciones, del contexto dado o de la coherencia interna.

En RAG hay un contexto explícito contra el cual evaluar la fidelidad.

MAGESH ET AL. (2025)

Sistemas con citas

Incorrecta: contiene información factualmente inexacta.
Mal fundamentada (misgrounded): cita una fuente que no respalda la afirmación o que no es aplicable.

Captura el caso de una cita real que no dice lo que se le atribuye.

DOS RASGOS DISTINGUEN A LA ALUCINACIÓN DEL ERROR GENÉRICO

Plausibilidad: es lingüística y temáticamente coherente; no se detecta a simple vista.
Ausencia de soporte respecto de una referencia: el mundo, el contexto o la fuente citada. Toda afirmación sobre alucinación es relativa a una referencia.

No todo error es alucinación

- Error de razonamiento sobre premisas correctas
- Respuesta desactualizada (verdadera al corte)
- Alucinación: contenido sin apoyo verificable

Maynez et al. (2020); Ji et al. (2023); Huang et al. (2025); Magesh et al. (2025). Documento maestro, Sección 5.1–5.2.

Verdadero, fiel y atribuible son tres propiedades distintas

Eje	Pregunta que responde	Se evalúa contra	Ejemplo de fallo
Factualidad	¿Es verdadera la afirmación?	Hechos del mundo o una fuente confiable (p. ej., Wikipedia en FActScore)	Afirmar un año de publicación incorrecto.
Fidelidad / groundedness	¿Está respaldada por el contexto entregado al modelo?	Los documentos recuperados z	El pasaje sitúa las mejores imágenes entre las semanas 24 y 30; la respuesta, entre la 20 y la 32.
Atribución / citación	¿La fuente citada respalda exactamente la afirmación que acompaña?	El documento específico citado	Citar un caso real que no contiene la regla que se le atribuye.

LO QUE HACE RAG

Actúa directamente sobre la fidelidad (hay un contexto contra el cual evaluar) y solo indirectamente sobre la factualidad: el contexto además debe ser correcto.

LO QUE NO SE DEBE CONFUNDIR

Una oración puede ser verdadera y aun así infiel al contexto; y puede ser fiel al contexto y falsa si el documento recuperado está equivocado.

Elaboración propia a partir de Huang et al. (2025), Gao et al. (2023), Magesh et al. (2025) y Rashkin et al. (2023). Ejemplo de fidelidad: Niu et al. (2024, preprint, Tabla 1).

RAG ataca la falta de conocimiento, no el objetivo de entrenamiento

Causa	Mecanismo	¿Actúa RAG sobre ella?
Objetivo de máxima verosimilitud	Se recompensa lo probable, no lo verdadero	**No directamente.** RAG cambia el condicionamiento, no la función objetivo.
Conocimiento paramétrico limitado (cola larga)	Hechos raros mal representados en θ	**Sí.** Si el hecho está en el corpus y se recupera.
Desactualización	Corte temporal del entrenamiento	**Sí, con condiciones.** Índice actualizado; parcial si hay documentos obsoletos.
Incertidumbre e incentivos a adivinar	Se premia responder sobre abstenerse	**No directamente.** Requiere abstención o evaluación de la evidencia.
Decodificación estocástica	Muestreo de tokens poco probables	**No.** Es independiente de la recuperación.
Falsedades imitativas y falsas premisas	Reproducción de errores frecuentes o aceptación de premisas	**Parcialmente.** Si el contexto contradice la premisa y el modelo lo usa.

Interpretación. RAG ataca con claridad las causas ligadas a la disponibilidad del conocimiento; por eso es razonable esperar que reduzca la alucinación sin eliminarla.

Kalai et al. (2025); Mallen et al. (2023); Shuster et al. (2021); Lin et al. (2022); Lewis et al. (2020). Tabla de elaboración propia (Documento maestro, Tabla 3).

Un LLM calcula qué es probable, no qué es verdadero

ECUACIÓN 3 · REGLA DE LA CADENA

$$p_\theta(y \mid x) = \prod_{i=1}^{n} p_\theta(y_i \mid y_{<i}, x)$$

Probabilidad de la secuencia de salida y dada la entrada x; θ agrupa los parámetros del modelo.

ECUACIÓN 4 · SOFTMAX CON TEMPERATURA

$$p_\theta(y_i = v \mid y_{<i}, x) = \frac{\exp(z_v / T)}{\sum_{v' \in V} \exp(z_{v'} / T)}$$

z_v: logit del token candidato v; T < 1 concentra la distribución y T > 1 la aplana.

ECUACIÓN 5 · OBJETIVO DE ENTRENAMIENTO

$$L(\theta) = -\sum_i \log p_\theta(y_i \mid y_{<i}, x)$$

Entropía cruzada: penaliza dar baja probabilidad a lo que aparece en el corpus.

Vaswani et al. (2017); Kalai et al. (2025). Documento maestro, Sección 7 (Ecuaciones 3–5).

TRES CONSECUENCIAS

1. La probabilidad mide plausibilidad según lo aprendido, no verdad: fluidez y veracidad pueden disociarse.
2. La softmax nunca asigna probabilidad cero: ninguna afirmación falsa queda excluida por la arquitectura.
3. La pérdida no incluye ningún término de verificación ni de abstención.

RAG modifica el condicionamiento de la Ec. (3) —añade un contexto z— pero conserva las tres propiedades.

RAG responde «a libro abierto», pero sigue siendo un generador

Memoria paramétrica · pesos θ

- Conocimiento codificado en los pesos del generador
- Compacta y rápida, pero opaca
- Difícil de actualizar
- Cobertura desigual: los hechos raros se representan peor

Memoria no paramétrica · corpus D

- Corpus externo indexado para búsqueda
- Editable, ampliable o reemplazable sin reentrenar
- Cada fragmento recuperado es inspeccionable
- RAG original: ≈21 millones de fragmentos de 100 palabras (Wikipedia)

PREPARACIÓN DEL CORPUS (ANTES DE RESPONDER)

1 · Fragmentar
Chunks de tamaño acotado

→

2 · Codificar
E(d) ∈ ℝ^m con un codificador

→

3 · Indexar
Vecinos más cercanos (FAISS)

Recuperación del top-k

Densa: DPR, doble codificador, producto interno
Dispersa: TF-IDF, BM25 · **Híbrida** · **Re-ranking**

Qué problema resuelve: acceso al conocimiento (disponibilidad, actualidad y trazabilidad). Esto delimita de entrada lo que puede esperarse del mecanismo.

Cada decisión (tamaño del fragmento, codificador, índice, k) es una fuente potencial de error.

Lewis et al. (2020); Karpukhin et al. (2020); Shuster et al. (2021). Documento maestro, Sección 8.

Tres ecuaciones explican qué hace RAG, y qué no

1 **Recuperación: puntuar cada documento**

EC. 7 (DPR)

$$s(x, z) = E_d(z)^T E_q(x)$$

Representa: Vectores de consulta y de documento; el producto crece si apuntan en direcciones parecidas.
Implica: Mide cercanía temática en el espacio aprendido: no implicación lógica ni verdad.

2 **Peso: confianza del recuperador**

EC. 8

$$p_\eta(z \mid x) = \frac{\exp(s(x, z))}{\sum_{z' \in \text{top-k}(x)} \exp(s(x, z'))}$$

Representa: Softmax sobre las puntuaciones, restringida al top-k; los pesos suman uno.
Implica: Algún documento recibe peso alto aunque ninguno sea relevante.

3 **Generación: mezclar lo que dice cada documento**

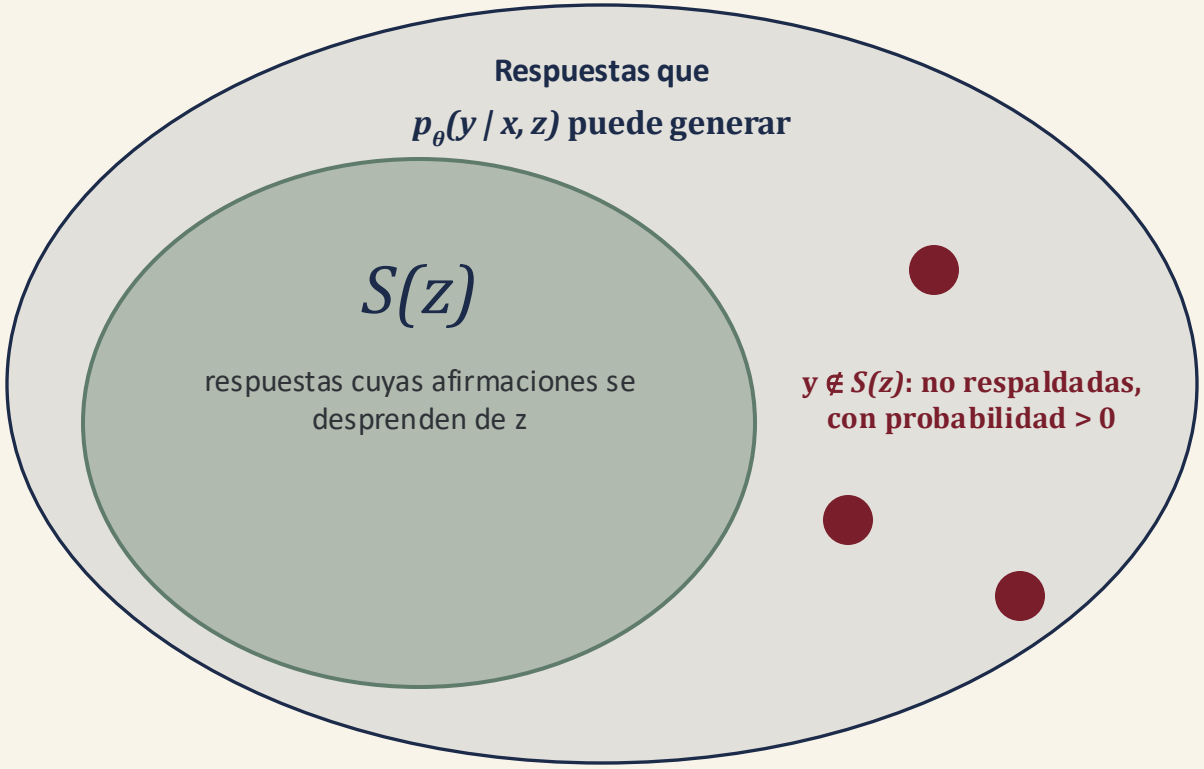
EC. 10 (RAG-SEQUENCE)

$$p_{RAG}(y \mid x) \approx \sum_{z \in \text{top-k}(x)} p_\eta(z \mid x) \prod_{i=1}^{n} p_\theta(y_i \mid x, z, y_{<i})$$

Representa: Cada documento pondera lo que diría el generador condicionado en él.
Implica: Un documento irrelevante con peso no despreciable contribuye a la respuesta.

Lewis et al. (2020); Karpukhin et al. (2020). RAG-Token (Ec. 11) marginaliza en cada token. Con vectores normalizados, el producto interno coincide con la similitud coseno (Ec. 6).

Recuperar evidencia no obliga a que la respuesta esté respaldada



ECUACIÓN 13 · RESPUESTAS FIELMENTE FUNDAMENTADAS

$$S(z) = \{ y : \forall a \in A(y), z \vDash a \}$$

A(y): afirmaciones atómicas de y · z ⊨ a: un lector competente concluiría a desde z

ECUACIÓN 14 · LA PROBABILIDAD FUERA DE S(z) NO ES CERO

$$P(y \notin S(z) \mid x, z) = \sum_{y \notin S(z)} p_\theta(y \mid x, z) > 0$$

La softmax asigna probabilidad positiva a todo token del vocabulario (T > 0)

1 · Con muestreo, ninguna respuesta no respaldada queda excluida.

2 · Con decodificación determinista, nada garantiza que la elegida esté en S(z).

3 · θ sigue activa: la misma memoria paramétrica que alucina sin recuperación.

4 · La marginalización pondera por similitud, no por implicación.

RAG cambia de qué distribución se genera la respuesta, no qué respuestas están permitidas.

Lewis et al. (2020); Min et al. (2023); Rashkin et al. (2023). La desigualdad (14) no dice que alucinar sea probable, sino que no es imposible por construcción; su magnitud es empírica.

Tener una fuente no equivale a estar bien fundamentado

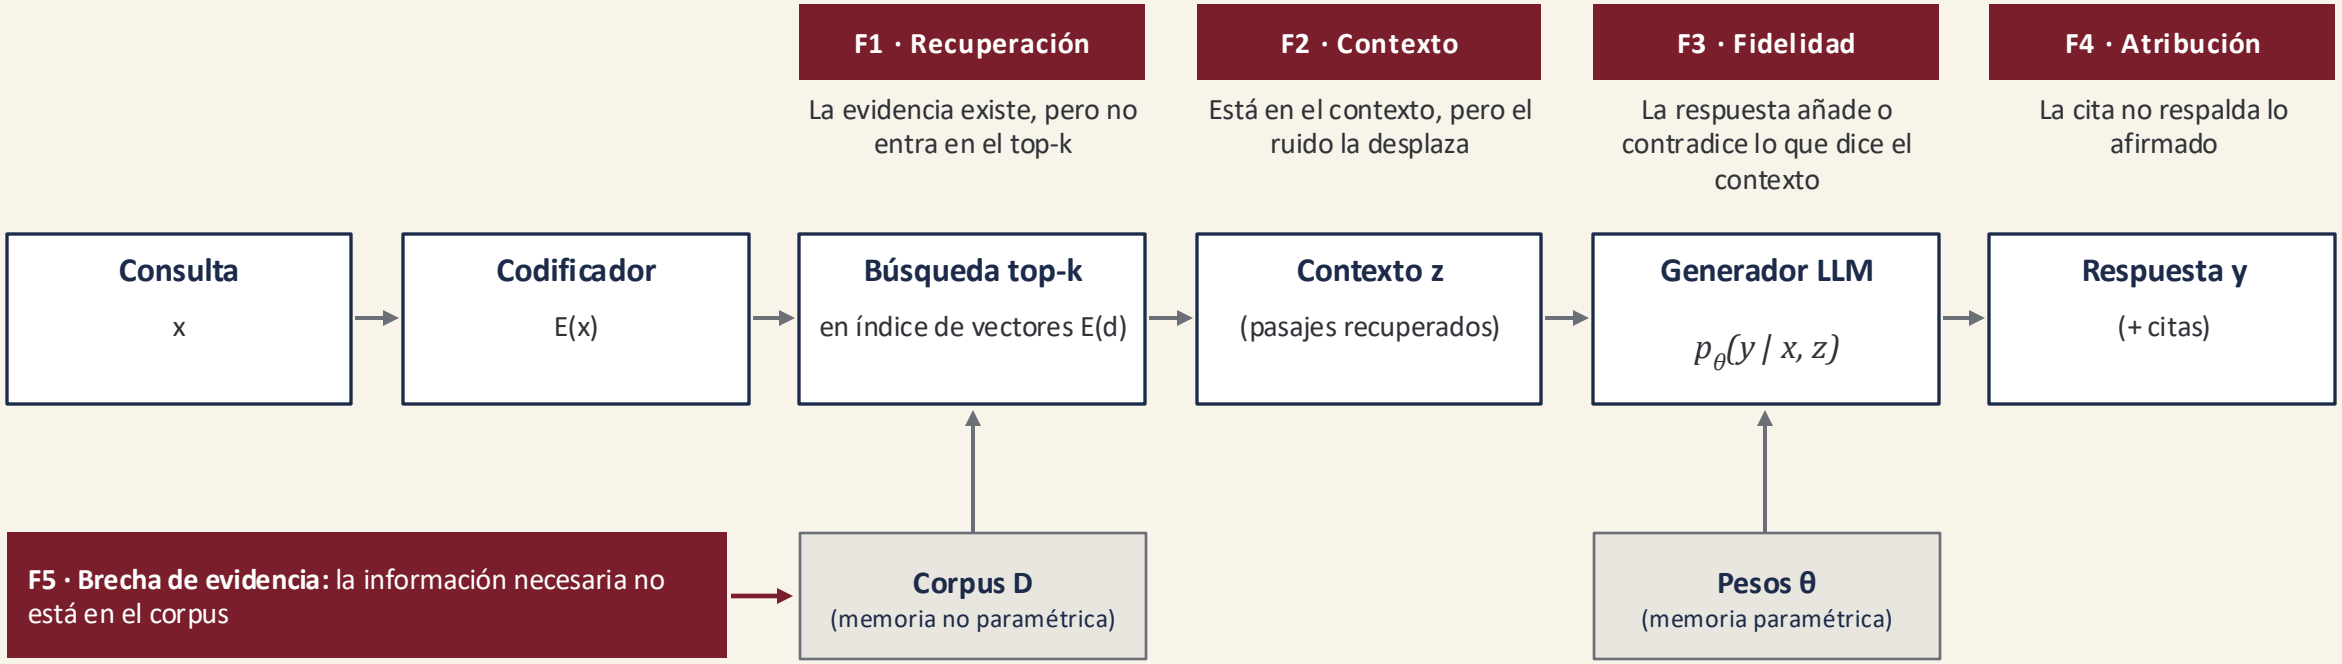
Concepto	Qué es	Qué garantiza	Qué no garantiza
Recuperación PROCESO	Selección de fragmentos del corpus por similitud con la consulta	Que el contexto contenga fragmentos parecidos a la consulta	Que contengan la respuesta, que sean correctos o que sean aplicables
Generación PROCESO	Producción de la respuesta a partir de $p_\theta(y \mid x, z)$	Una respuesta fluida condicionada en x y z	Que use z, ni que cada afirmación esté respaldada por z
Grounding (fidelidad) PROPIEDAD	Propiedad de la salida: sus afirmaciones están respaldadas por el contexto	Si se cumple, que no agrega ni contradice información del contexto	Que el contexto sea verdadero: una respuesta fiel a un documento erróneo es fiel y falsa
Atribución / citación PROPIEDAD	Vínculo explícito entre cada afirmación y la fuente que la respalda	Si la cita es correcta, que el usuario pueda verificar la afirmación	Que la cita respalde realmente lo afirmado: su presencia no prueba el soporte

Recuperación y generación son procesos del sistema; grounding y atribución son propiedades de la salida que deben verificarse. Un pipeline RAG estándar implementa los procesos, pero no comprueba las propiedades.

Una cita es una afirmación más del modelo —que la fuente respalda lo dicho— y puede ser alucinada como cualquier otra.

Documento maestro, Sección 8.7 (Tabla 4) y Sección 10.4. Elaboración propia a partir de Lewis et al. (2020), Rashkin et al. (2023) y Magesh et al. (2025).

El error puede nacer en cinco puntos del pipeline



PROPUESTA NUESTRA

$$P(H) = P(H \mid \neg E)\cdot P(\neg E) + P(H \mid E)\cdot P(E)$$

H: respuesta con alucinación · E: el contexto contiene evidencia suficiente y correcta

P(¬E)

Evidencia ausente (F5) o no recuperada (F1): se corrige mejorando el recuperador.

P(H | ¬E)

Sin evidencia, el modelo rellena con memoria paramétrica en vez de abstenerse.

P(H | E)

Aun con evidencia suficiente: fallos F2, F3 y F4. Solo la verificación los reduce.

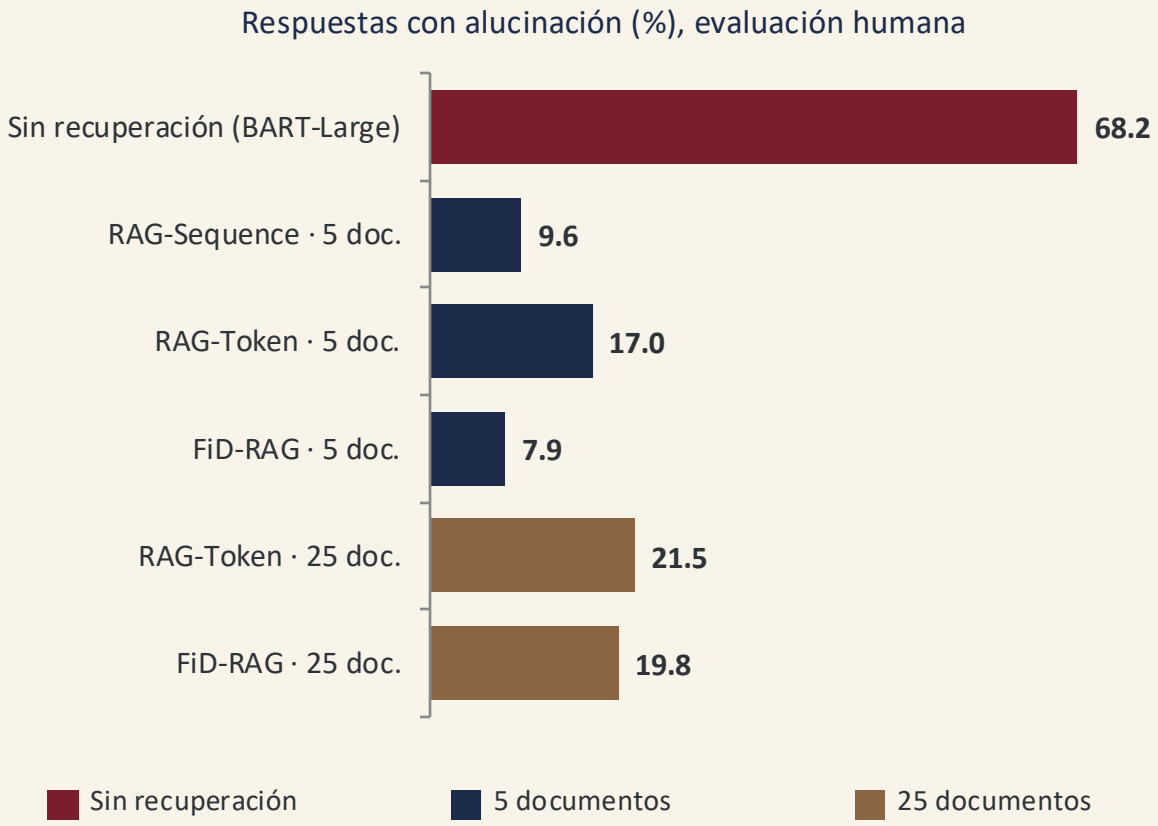
(Elaboración propia a partir de Lewis et al., 2020; Magesh et al., 2025, Fig. 3). Mejorar un solo término no lleva P(H) a cero mientras los otros sean positivos.

Cada punto de fallo tiene su mecanismo, su ejemplo y su mitigación

Punto de fallo	Mecanismo principal	Ejemplo conceptual	Mitigación asociada
F1 Recuperación	Similitud vectorial ≠ relevancia: el top-k omite la evidencia	«Error moral» recupera «torpeza moral»	Híbrido, re-ranking, reformulación; CRAG, FLARE
F2 Contexto / relevancia	Ruido, distractores, posición, contradicciones	Cifra correcta en el fragmento 6 de 10	Filtrado, compresión, orden; Self-RAG (ISREL), CRAG
F3 Generación / fidelidad	El contexto condiciona pero no restringe; memoria paramétrica activa	«Entre 20 y 32 semanas» frente a «24 a 30»	Self-RAG (ISSUP), CoVe, verificador posterior, abstención
F4 Citación / atribución	La cita se genera o asigna sin comprobar implicación	Caso real que no respalda la regla atribuida	Verificación de citas por NLI; ALCE como evaluación
F5 Brecha de evidencia	La información no existe en el corpus o está desactualizada	Corpus de guías prácticas ante una pregunta de jurisprudencia	Ampliar y curar fuentes; abstención; búsqueda externa (CRAG)
F6 Conflicto y autoridad	Transversal: fuentes contradictorias, obsoletas o inaplicables; falsas premisas	Precedente revocado presentado como vigente	Metadatos de vigencia y jerarquía; detección de conflicto; revisión humana

Evidencia: F1 Shuster et al. (2021), Magesh et al. (2025) · F2 Liu et al. (2024), Shi et al. (2023), Cuconasu et al. (2024) · F3 Niu et al. (2024) · F4 Gao et al. (2023), Liu et al. (2023) · F5 Chen et al. (2024) · F6 Xie et al. (2024). Elaboración propia (Tabla 5).

En diálogo, recuperar baja la alucinación de 68,2 % a 7,9–17,0 %



DISEÑO

Evaluación humana de 100 respuestas por modelo (Wizard of Wikipedia, temas no vistos); modelos de escala BART-Large (≈400 M de parámetros); recuperación sobre Wikipedia.

RESULTADO

Los autores resumen una reducción de más del 60 % de respuestas alucinadas. Con 25 documentos en lugar de 5, la alucinación aumentó (RAG-Token 17,0 → 21,5 %; FiD-RAG 7,9 → 19,8 %). RAG-Token, pensado para fusionar documentos, alucinó más que RAG-Sequence.

LIMITACIONES

100 respuestas por modelo, anotadores del laboratorio, modelos moderados de 2021, un solo dominio y un corpus sin documentos contradictorios.

RESPALDA H1 · H2

Shuster et al. (2021), Tabla 4 (evaluación humana). Las cifras no son comparables con las de otros estudios: otra muestra, tarea y definición de alucinación.

Con RAG y corpus autorizados, las herramientas jurídicas aún alucinan

202 consultas · 4 categorías (80 · 70 · 22 · 30)

Ejecutadas entre marzo y mayo de 2024

Evaluación preregistrada · derecho de EE. UU.

Acuerdo entre evaluadores: κ = 0,77 (85,4 %)

17–33 %

alucinó cada herramienta jurídica evaluada; menos que GPT-4

65 %

Lexis+ AI: respuestas correctas y fundamentadas

≈41 %

Westlaw AI-AR: correctas y fundamentadas; alucinó casi el doble que las otras herramientas jurídicas

62 %

Ask Practical Law AI: respuestas incompletas (corpus más limitado)

DEFINICIÓN OPERATIVA

Alucinada = incorrecta o mal fundamentada (cita una fuente que no respalda o que no es aplicable). Las alucinaciones persistieron en todas las categorías, incluidas las preguntas generales tipo examen de abogacía.

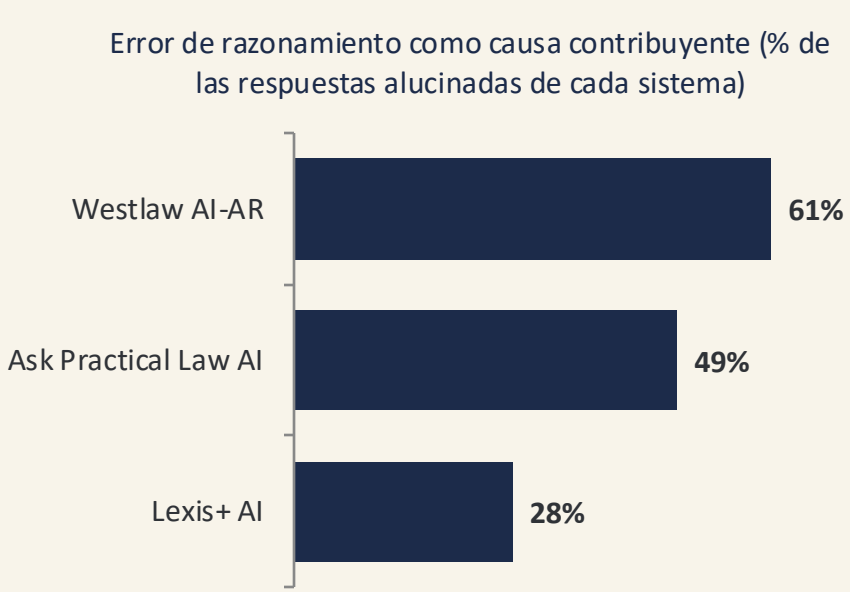
LECTURA CORRECTA

ALCANCE

No es «RAG alucina entre 17 % y 33 %». Es lo que estas tres herramientas hicieron en este conjunto de 202 consultas, diseñado para ser desafiante; no es una estimación insesgada de la frecuencia poblacional.

Magesh et al. (2025), J. Empirical Legal Studies, 22(2). Referencia orientativa, no comparable: LLM de propósito general alucinaron 58–82 % en consultas jurídicas (Dahl et al., 2024; otra tarea y definición).

En el caso jurídico, los errores nacen en etapas distintas



Recuperación ingenua

La «doctrina del error moral» recupera «torpeza moral»; un juez ficticio recupera un caso real con demandante de apellido parecido.

Autoridad inaplicable

Cita documentos de otra jurisdicción, de otro tribunal o precedentes revocados.

Complacencia

No corrige una premisa falsa y añade información falsa (algunos sistemas sí la corrigieron).

Error de razonamiento

Con el pasaje correcto a la vista, atribuye al tribunal lo que describía la conducta de la parte demandada.

LO QUE AFIRMA LA RESPUESTA

Cita un caso real y vigente como respaldo de la afirmación.

SIN SOPORTE →

LO QUE DICE EL DOCUMENTO CITADO

El texto del caso describe otro caso, que sí fue revocado.

La cita «existe», pero la afirmación que sostiene es incorrecta. Ilustración conceptual.

Magesh et al. (2025), Tabla 6 y Fig. 2. Categorías no excluyentes; proporciones sobre las respuestas alucinadas de cada sistema. Recuadro inferior: ilustración conceptual, no un resultado.

Con el contexto delante, persisten afirmaciones y citas sin soporte

Fidelidad dentro de RAG · RAGTruth (Niu et al., 2024)

PASAJE RECUPERADO (PARAFRASEADO)

Indica que las ecografías 3D se realizan mejor entre las semanas 20 y 32, y que las mejores imágenes se obtienen entre las semanas 24 y 30.

RESPUESTA GENERADA

Recomienda programar la cita «entre las semanas 20 y 32 para obtener las mejores imágenes».

CONFLICTO EVIDENTE CON EL CONTEXTO

- ≈18 000 respuestas anotadas (17 838 en el preprint), seis modelos.
- La información sin base fue más frecuente que la contradicción directa.
- Detección difícil: F1 de 68,3 % (prompt con GPT-4-turbo) y 80,7 % (Llama-2-13B ajustado), por respuesta.
- Cálculo propio: 48 de 992 respuestas de GPT-4 en QA (≈4,8 %) con al menos una alucinación.

Atribución · ALCE y Liu et al. (2023)

50 %

ELI5 (ALCE): incluso los mejores modelos carecían de soporte completo de las citas en la mitad de los casos.

51,5 %

74,5 %

51,5 % de las oraciones estaba totalmente respaldada por sus citas;
74,5 % de las citas respaldaba su oración.
Auditoría humana de Bing Chat, NeevaAI, perplexity.ai y YouChat (2023).

Una cita presente no garantiza soporte completo.

Niu et al. (2024, cifras del preprint); Gao et al. (2023); Liu et al. (2023). Fuentes y condiciones distintas: no comparar los porcentajes entre sí.

Los estudios convergen: la recuperación ayuda, ninguno elimina el error

Estudio	Sistema / población	Resultado clave	Respalda	Alcance
Shuster et al. (2021)	Modelos de diálogo tipo BART, con y sin recuperación	68,2 % sin recuperación frente a 7,9–17,0 % con 5 documentos; más documentos, más alucinación	H1 · H2	Diálogo; Wikipedia; 2021
Magesh et al. (2025)	3 herramientas jurídicas comerciales + GPT-4	Cada herramienta alucinó entre 17 % y 33 %; menos que GPT-4	H1 · H2 · H3	Derecho de EE. UU.; 202 consultas; no es estimación poblacional
Niu et al. (2024)	6 LLM con contexto dado (≈18 000 respuestas anotadas)	Información sin base y contradicciones con el contexto; detección difícil	H2 · H3	QA, resumen y datos a texto
Gao et al. (2023)	LLM con recuperación y citas (ALCE)	ELI5: soporte de citas incompleto en 50 % de los casos (mejores modelos)	H2 (F4)	Respuestas largas con citas
Liu et al. (2023)	4 motores de búsqueda generativos	51,5 % de oraciones totalmente respaldadas; 74,5 % de citas precisas	H2 (F4)	Sistemas comerciales de 2023
Min et al. (2023)	InstructGPT, ChatGPT y PerplexityAI	FActScore humano: 42,5 % · 58,3 % · 71,5 %	H1 · H2	Biografías (183 personas)
Chen et al. (2024)	6 LLM de 2023 (benchmark RGB)	Débiles en rechazo negativo, integración de información y robustez contrafactual	H3 (F5, F6)	Escenarios simplificados

Interpretación. En comparaciones directas la recuperación reduce la alucinación; ningún estudio la elimina y los errores residuales aparecen en todas las etapas. La conclusión general no es una tasa sino una propiedad: depende del dominio, el corpus, el recuperador, el generador y la tarea, y debe medirse en cada sistema.

Documento maestro, Tabla 7. Los porcentajes de estudios distintos usan muestras, tareas y definiciones diferentes: no son directamente comparables.

Evaluar RAG exige medir cada dimensión por separado

Dimensión	Pregunta	Marco que la mide	Fallo
Calidad de recuperación	¿El top-k contiene la evidencia necesaria?	Recall@k, Precision@k	F1, F5
Relevancia del contexto	¿Lo recuperado es pertinente y enfocado?	RAGAS, ARES	F1, F2
Fidelidad	¿Cada afirmación está respaldada por el contexto?	RAGAS, ARES, RAGTruth	F3
Factualidad	¿Es verdadera según una fuente de referencia?	FActScore	F1–F6
Relevancia de la respuesta	¿Responde lo preguntado?	RAGAS, ARES	Desvíos
Calidad de citas	¿Las citas respaldan las afirmaciones?	ALCE; Liu et al. (2023)	F4
Abstención	¿Rechaza si la evidencia es insuficiente?	RGB (rechazo negativo)	F5

ECUACIÓN 16 · RECUPERACIÓN

$$\text{Recall@k} = |R(x) \cap Z| \,/\, |R(x)|$$

$$\text{Precision@k} = |R(x) \cap Z| \,/\, k$$

ECUACIÓN 18 · FIDELIDAD (RAGAS)

$$F = |V| \,/\, |S| \quad con\ V \subseteq S$$

S: enunciados de la respuesta · V: los inferibles del contexto

ECUACIÓN 17 · FACTUALIDAD ATÓMICA (FACTSCORE)

$$f(M) = E_x[\,(1 \,/\, |A_y|) \sum_{a \in A_\{y\}} 1[\,a\ respaldada\ por\ C\,]\,]$$

Proporción media de hechos atómicos respaldados por una fuente C; se calcula sobre respuestas sin abstención.

CUATRO LIMITACIONES TRANSVERSALES DE LA EVALUACIÓN

Dependencia de la referencia
cambiar la fuente cambia la cifra

Evaluadores imperfectos
NLI y LLM como juez introducen errores

Costo de la evaluación humana
exige experticia y tiempo

El solapamiento léxico no basta
F1 correlaciona poco con juicios humanos

Min et al. (2023); Es et al. (2024); Saad-Falcon et al. (2024); Gao et al. (2023); Chen et al. (2024); Niu et al. (2024); Shuster et al. (2021). Documento maestro, Secciones 12.1–12.4.

Las limitaciones son estructurales y el diseño exige compromisos

SIETE LIMITACIONES ESTRUCTURALES

1. **Sin restricción de fidelidad**
   El contexto condiciona, no restringe (Ec. 14).
2. **La similitud no es relevancia ni verdad**
   La relevancia jurídica, técnica o temporal exige más que texto.
3. **Dependencia del corpus**
   Una respuesta fiel a un documento erróneo es fiel y falsa.
4. **Uso imperfecto del contexto**
   Posición, ruido y más documentos degradan la respuesta.
5. **Sin abstención nativa**
   El pipeline estándar siempre produce una respuesta.
6. **Conflicto sin regla de resolución**
   Deciden el orden, la redacción y la frecuencia, no la jerarquía.
7. **Opacidad y difícil auditoría**
   En sistemas cerrados solo cabe una auditoría de caja negra.

COMPROMISOS DE DISEÑO

Compromiso	Se gana	Se arriesga
Contexto ↔ ruido	Probabilidad de incluir la evidencia	Distracción y más alucinación (Shuster: de 5 a 25 documentos)
Recall ↔ precisión	Recall@k al subir k	Precision@k: evidencia diluida (F2)
Naturalidad ↔ grounding	Fidelidad y citas	Fluidez e interés conversacional
Cobertura ↔ costo	Cobertura y control	Latencia, memoria (índice de 80 GB de RAM en Shuster) y costo de inferencia
Diversidad ↔ consistencia	Cobertura de perspectivas	Contradicciones sin regla de resolución
Mejor recuperación ↔ fidelidad	Menor P(¬E)	P(H | E) no cambia

En aplicaciones de alto riesgo el compromiso se resuelve a favor del grounding.

Shuster et al. (2021); Niu et al. (2024); Liu et al. (2024); Asai et al. (2024); Chen et al. (2024); Xie et al. (2024); Magesh et al. (2025). Documento maestro, Secciones 13–14.

Cada alternativa interviene en un punto distinto del pipeline

ANTES DE GENERAR

CRAG

Yan et al. (2024) · preprint

IDEA

Un evaluador ligero estima la calidad de lo recuperado y activa acciones: correcto, incorrecto (búsqueda web) o ambiguo.

ATACA

F1 · F2 · F5 (parcial)

LÍMITE

La web añade ruido; no verifica la fidelidad (F3).

DURANTE LA GENERACIÓN

Self-RAG

Asai et al. (2024)

IDEA

Un único modelo decide cuándo recuperar y critica pasajes y generaciones con tokens de reflexión.

ATACA

F2 · F3 (parcial) · F4

LÍMITE

La autocrítica es del mismo modelo; exige entrenamiento específico.

FLARE

Jiang et al. (2023)

IDEA

Genera una oración tentativa y recupera si contiene tokens de baja confianza.

ATACA

F1 en textos largos · F5 (parcial)

LÍMITE

Un modelo puede estar equivocado con alta confianza: entonces no recupera.

DESPUÉS DE GENERAR

Chain-of-Verification

Dhuliawala et al. (2024)

IDEA

Redacta, plantea preguntas de verificación, las responde de forma independiente y corrige.

ATACA

F3 y errores paramétricos

LÍMITE

El verificador es el mismo modelo que se equivocó.

SelfCheckGPT

Manakul et al. (2023)

IDEA

Compara la respuesta con muestras adicionales: lo inventado tiende a divergir.

ATACA

Señala F3 (no corrige)

LÍMITE

No detecta alucinaciones consistentes; detecta, no corrige.

Evidencia reportada por los propios autores en benchmarks concretos; no extrapolar sin evaluación independiente. Documento maestro, Sección 15. CRAG: versión preprint (arXiv).

Ninguna alternativa cubre todos los fallos, y todas cuestan

Enfoque	Interviene	Reduce	Limitación principal	Costo
LLM sin recuperación	— (línea base)	—	Cola larga, desactualización, sin trazabilidad	Bajo
RAG tradicional	Antes de generar	Falta o desactualización del conocimiento	No garantiza fidelidad ni atribución; sensible al ruido	Medio
RAG + re-ranking / filtrado	Entre recuperación y generación	F1, F2	No actúa sobre la generación ni la cita	Medio
Self-RAG	Durante la generación	F2, F3 (parcial), F4	Autoevaluación del mismo modelo; requiere entrenamiento	Alto
CRAG	Entre recuperación y generación	F1, F2, F5 (parcial)	La web añade ruido; no verifica la generación	Medio-alto
FLARE	Durante la generación	F1 (textos largos), F5 (parcial)	Depende de la confianza calibrada; requiere probabilidades	Alto
Chain-of-Verification	Después del borrador	F3 y errores paramétricos	El verificador es el mismo modelo	Medio
Detección por consistencia	Después de generar	Señala F3 (no corrige)	No detecta errores consistentes	Alto
Verificación de atribución + abstención + revisión humana	Sobre la salida	F3, F4, F5	Errores del verificador; costo humano. Composición propia, no evaluada	Variable

Ninguna fila cubre todas las categorías de fallo; reducir más error se paga en complejidad, latencia o costo humano.

Documento maestro, Tabla 11 (elaboración propia a partir de Asai et al., 2024; Yan et al., 2024; Jiang et al., 2023; Dhuliawala et al., 2024; Manakul et al., 2023; Rashkin et al., 2023).

La mitigación de RAG es condicional, y las hipótesis lo respaldan

H1 — RESPALDADA

Shuster: 68,2 % → 7,9–17,0 %. Magesh: menos que GPT-4. Min: mayor FActScore con búsqueda.

H2 — RESPALDADA

Magesh: 17–33 %. RAGTruth. ELI5: 50 % sin soporte completo. Liu: 51,5 %.

H3 — RESPALDADA

Tipología de Magesh, capacidades de Chen, puntos de fallo de Barnett, efectos de posición y ruido.

H4 — PARCIALMENTE RESPALDADA

Mejoras reportadas por los propios autores; faltan evaluaciones independientes y en alto riesgo.

Factor	RAG mitiga con fuerza cuando…	RAG mitiga débilmente o falla cuando…
Cobertura del corpus	La respuesta está explícita en el corpus	La información no existe o es posterior a la actualización (F5)
Naturaleza de la pregunta	Factual, acotada, con respuesta localizable	Exige síntesis, razonamiento jurídico o técnico, o es indeterminada
Recuperación	Consulta y documento comparten formulación	Hay sinonimia, ambigüedad o la relevancia depende de metadatos (F1)
Contexto	Breve, limpio y consistente	Largo, con distractores, contradicciones o evidencia en el medio (F2, F6)
Generación	Respuesta corta y casi extractiva	Respuesta larga y abstractiva, con muchas proposiciones (F3)
Atribución	Las citas se verifican contra el texto	Las citas se asignan sin comprobar implicación (F4)
Abstención	El sistema declara insuficiencia de evidencia	El sistema siempre responde

Documento maestro, Tablas 12 y 13 (síntesis interpretativa a partir de las Secciones 10, 11 y 14). Evidencia de H4 mayoritariamente reportada por los propios autores.

Propuesta: una capa de control por cada término del riesgo

1

Evidencia

Corpus curado y versionado, con metadatos de vigencia y autoridad.

Reduce F5 · F6

2

Recuperación evaluada

Recuperación híbrida, re-ranking y un evaluador de la calidad de la evidencia.

Reduce P(¬E): F1 · F2

3

Generación con abstención

Instrucción y entrenamiento para declarar insuficiencia cuando la evidencia no alcanza.

Reduce P(H | ¬E)

4

Verificación de afirmaciones

Cada afirmación se contrasta con su cita mediante un verificador independiente del generador.

Reduce P(H | E): F3 · F4

5

Supervisión humana

Revisión proporcional al riesgo del dominio.

Proporcional al riesgo

PROPUESTA NUESTRA

El riesgo se descompone (Ec. 15)

$$P(H) = P(H \mid \neg E)\cdot P(\neg E) + P(H \mid E)\cdot P(E)$$

Mejorar el recuperador reduce P(¬E); enseñar a abstenerse reduce P(H | ¬E); verificar la generación reduce P(H | E).

Ninguna intervención sobre un solo término lleva P(H) a cero mientras los otros sean positivos.

No está evaluada como sistema integrado: es una síntesis de componentes con respaldo parcial.

Documento maestro, Sección 17.4 (propuesta propia). Componentes: Rashkin et al. (2023); Gao et al. (2023); Yan et al. (2024); Asai et al. (2024); Dhuliawala et al. (2024); Magesh et al. (2025).

Un experimento controlado para hacer visible el argumento

A — LLM sin evidencia

Responde solo con su memoria paramétrica.

Observa: línea base de afirmaciones plausibles no respaldadas.

→

B — LLM + evidencia recuperada

Responde con pasajes del corpus controlado e instrucción de citar.

Observa: cambio en factualidad y fidelidad (H1) y errores residuales (H2).

→

C — LLM + evidencia + verificación

Cada afirmación de B se contrasta con su pasaje citado; las no respaldadas se marcan o eliminan y el sistema se abstiene si no queda soporte.

Observa: cuántos errores detecta y a qué costo (H4).

BANCO DE 8–12 PREGUNTAS EN CINCO ESCENARIOS DE EVIDENCIA

Evidencia suficiente	Evidencia insuficiente	Evidencia distractora	Evidencia contradictoria	Posición de la evidencia
F3 aun con E verdadero	F5: se espera abstención	F2	F6: versión vigente vs. derogada	inicio vs. medio del contexto

Unidad: la afirmación atómica. **Métricas:** precisión factual atómica, fidelidad al contexto, recall y precisión de citas, abstención correcta e incorrecta y desempeño del verificador. Anotación independiente por dos integrantes (κ de Cohen).

QUÉ PERMITIRÍA DEMOSTRAR (EXPECTATIVAS, NO RESULTADOS)

- B muestra más afirmaciones respaldadas que A con evidencia suficiente (H1).
- B conserva afirmaciones sin respaldo: distractores, contradicciones, respuestas largas (H2, H3).
- Sin evidencia, B a veces responde en lugar de abstenerse.
- C detecta parte de ese error residual, no todo, con más latencia (H4).

PROPUESTA · SIN RESULTADOS

Trabajo futuro, no un experimento realizado. Valor demostrativo, no inferencial: no estima tasas ni es evidencia sobre «RAG en general».

Documento maestro, Sección 19 (propuesta propia). Inspirado en Min et al. (2023), Niu et al. (2024), Gao et al. (2023), Chen et al. (2024) y Liu et al. (2024).

CONCLUSIÓN

RAG mitiga las alucinaciones, pero no es una garantía de veracidad

MATEMÁTICAMENTE

RAG añade un contexto al condicionamiento de un generador que sigue siendo probabilístico: la evidencia orienta la generación sin restringirla.

EMPÍRICAMENTE

La recuperación reduce la alucinación, a veces de forma sustancial; ningún estudio revisado la elimina, y los errores aparecen en todas las etapas.

CONCEPTUALMENTE

Tener una fuente no es lo mismo que estar correctamente fundamentado: eso es una propiedad de cada afirmación frente al texto citado.

PARA SISTEMAS REALES, LA CONFIABILIDAD EXIGE

1. **Evaluación de la evidencia**
2. **Verificación de afirmaciones**
3. **Abstención cuando corresponda**
4. **Supervisión proporcional al riesgo**

- Exigir evidencia específica a quien afirme «libre de alucinaciones».
- Incluir el costo de verificación en el cálculo de valor.
- Evaluar por componentes: recuperación, fidelidad, citas y abstención.



Referencias

Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2024). Self-RAG: Learning to retrieve, generate, and critique through self-reflection. ICLR 2024.

Barnett, S., Kurniawan, S., Thudumu, S., Brannelly, Z., & Abdelrazek, M. (2024). Seven failure points when engineering a retrieval augmented generation system [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2401.05856

Chen, J., Lin, H., Han, X., & Sun, L. (2024). Benchmarking large language models in retrieval-augmented generation. Proceedings of the AAAI Conference on Artificial Intelligence, 38(16), 17754–17762. https://doi.org/10.1609/aaai.v38i16.29728

Cuconasu, F., Trappolini, G., Siciliano, F., et al. (2024). The power of noise: Redefining retrieval for RAG systems. SIGIR 2024. https://doi.org/10.1145/3626772.3657834

Dahl, M., Magesh, V., Suzgun, M., & Ho, D. E. (2024). Large legal fictions: Profiling legal hallucinations in large language models. Journal of Legal Analysis, 16(1), 64–93.

Dhuliawala, S., Komeili, M., Xu, J., et al. (2024). Chain-of-verification reduces hallucination in large language models. Findings of ACL 2024, 3563–3578. https://doi.org/10.18653/v1/2024.findings-acl.212

Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAs: Automated evaluation of retrieval augmented generation. EACL 2024: System Demonstrations, 150–158. https://aclanthology.org/2024.eacl-demo.16

Farquhar, S., Kossen, J., Kuhn, L., & Gal, Y. (2024). Detecting hallucinations in large language models using semantic entropy. Nature, 630, 625–630. https://doi.org/10.1038/s41586-024-07421-0

Gao, T., Yen, H., Yu, J., & Chen, D. (2023). Enabling large language models to generate text with citations. EMNLP 2023, 6465–6488. https://doi.org/10.18653/v1/2023.emnlp-main.398

Huang, L., Yu, W., Ma, W., et al. (2025). A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. ACM Transactions on Information Systems, 43(2), 1–55. https://doi.org/10.1145/3703155

Ji, Z., Lee, N., Frieske, R., et al. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), 1–38. https://doi.org/10.1145/3571730

Jiang, Z., Xu, F. F., Gao, L., et al. (2023). Active retrieval augmented generation. EMNLP 2023, 7969–7992. https://doi.org/10.18653/v1/2023.emnlp-main.495

Kalai, A. T., Nachum, O., Vempala, S. S., & Zhang, E. (2025). Why language models hallucinate [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2509.04664

Kalai, A. T., & Vempala, S. S. (2024). Calibrated language models must hallucinate. STOC 2024. Versión preprint: https://doi.org/10.48550/arXiv.2311.14648

Karpukhin, V., Oguz, B., Min, S., et al. (2020). Dense passage retrieval for open-domain question answering. EMNLP 2020, 6769–6781. https://doi.org/10.18653/v1/2020.emnlp-main.550

Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474.

Lin, S., Hilton, J., & Evans, O. (2022). TruthfulQA: Measuring how models mimic human falsehoods. ACL 2022, 3214–3252. https://doi.org/10.18653/v1/2022.acl-long.229

Todas las referencias fueron verificadas en la página del editor, ACL Anthology, OpenReview/ICLR, NeurIPS, AAAI, MIT Press, Wiley o arXiv (Documento maestro).

Referencias

Liu, N. F., Lin, K., Hewitt, J., et al. (2024). Lost in the middle: How language models use long contexts. Transactions of the ACL, 12, 157–173. https://doi.org/10.1162/tacl_a_00638

Liu, N., Zhang, T., & Liang, P. (2023). Evaluating verifiability in generative search engines. Findings of EMNLP 2023, 7001–7025. https://doi.org/10.18653/v1/2023.findings-emnlp.467

Magesh, V., Surani, F., Dahl, M., Suzgun, M., Manning, C. D., & Ho, D. E. (2025). Hallucination-free? Assessing the reliability of leading AI legal research tools. Journal of Empirical Legal Studies, 22(2), 216–242. https://doi.org/10.1111/jels.12413

Mallen, A., Asai, A., Zhong, V., et al. (2023). When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. ACL 2023, 9802–9822. https://doi.org/10.18653/v1/2023.acl-long.546

Manakul, P., Liusie, A., & Gales, M. (2023). SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models. EMNLP 2023, 9004–9017. https://doi.org/10.18653/v1/2023.emnlp-main.557

Maynez, J., Narayan, S., Bohnet, B., & McDonald, R. (2020). On faithfulness and factuality in abstractive summarization. ACL 2020, 1906–1919. https://doi.org/10.18653/v1/2020.acl-main.173

Min, S., Krishna, K., Lyu, X., et al. (2023). FActScore: Fine-grained atomic evaluation of factual precision in long form text generation. EMNLP 2023, 12076–12100. https://doi.org/10.18653/v1/2023.emnlp-main.741

Niu, C., Wu, Y., Zhu, J., et al. (2024). RAGTruth: A hallucination corpus for developing trustworthy retrieval-augmented language models. ACL 2024, 10862–10878. https://doi.org/10.18653/v1/2024.acl-long.585

Rashkin, H., Nikolaev, V., Lamm, M., et al. (2023). Measuring attribution in natural language generation models. Computational Linguistics, 49(4), 777–840. https://doi.org/10.1162/coli_a_00486

Saad-Falcon, J., Khattab, O., Potts, C., & Zaharia, M. (2024). ARES: An automated evaluation framework for retrieval-augmented generation systems. NAACL 2024, 338–354. https://doi.org/10.18653/v1/2024.naacl-long.20

Shi, F., Chen, X., Misra, K., et al. (2023). Large language models can be easily distracted by irrelevant context. ICML 2023 (Vol. 202, pp. 31210–31227). PMLR.

Shuster, K., Poff, S., Chen, M., Kiela, D., & Weston, J. (2021). Retrieval augmentation reduces hallucination in conversation. Findings of EMNLP 2021, 3784–3803. https://doi.org/10.18653/v1/2021.findings-emnlp.320

Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30, 5998–6008.

Xie, J., Zhang, K., Chen, J., Lou, R., & Su, Y. (2024). Adaptive chameleon or stubborn sloth: Revealing the behavior of large language models in knowledge conflicts. ICLR 2024.

Yan, S.-Q., Gu, J.-C., Zhu, Y., & Ling, Z.-H. (2024). Corrective retrieval augmented generation [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2401.15884

Zhang, Y., Li, Y., Cui, L., et al. (2023). Siren's song in the AI ocean: A survey on hallucination in large language models [Preprint, v2]. arXiv. https://doi.org/10.48550/arXiv.2309.01219

Todas las referencias fueron verificadas en la página del editor, ACL Anthology, OpenReview/ICLR, NeurIPS, AAAI, MIT Press, Wiley o arXiv (Documento maestro).