GUION DE EXPOSICIÓN

Alucinaciones en los LLM y los límites de RAG

Universidad ICESI · Adri Martínez y Johan Guzmán · 28 diapositivas (26 de contenido y 2 de referencias)

Reparto

Quién	Qué cubre	Diapositivas	Tiempo aprox.
Adri	Apertura, problema, tesis, definiciones, teoría, arquitectura de RAG, matemática, argumento central, pipeline y fallos. Cierra con la conclusión.	1–13 y 26 (14 en total)	≈ 16 min
Johan	Evidencia empírica, caso jurídico, métricas, limitaciones, alternativas, comparación, síntesis, propuesta, experimento y demo.	14–25 (12 en total) + demo	≈ 17 min, demo incluida

Los tiempos salen de contar palabras a ritmo de conversación (unas 130 por minuto) y la demo está contada con su texto base; ajusten con la duración real.

Cómo usarlo

- Está escrito para decirse en voz alta, no para leerse palabra por palabra. Cada quien puede decirlo con sus palabras mientras mantenga las cifras y las advertencias.
- Las cajas «Ojo» marcan lo que no se puede decir de otra forma sin cambiar el sentido, sobre todo en cifras y en lo que son propuestas.
- La demo es de Johan y va después de la diapositiva 25, que presenta el experimento. Los textos entre corchetes se completan con la demo real.

ADRI Diapositiva 1 · Portada ≈ 0:58

Buenas, somos Adri y Johan. Hoy les vamos a hablar de las alucinaciones en los modelos de lenguaje y de qué tanto las resuelve RAG. La pregunta que guía todo el trabajo está en la portada: ¿hasta qué punto RAG mitiga realmente las alucinaciones y cuáles son sus límites como mecanismo de confiabilidad?

A la derecha ven una ficha de verificación. Ese estilo de expediente es a propósito: la idea de toda la presentación es que una afirmación que suena bien no vale nada hasta que se contrasta con evidencia, como haría un auditor con un documento. Yo, Adri, les cuento el problema, la teoría y cómo falla RAG por dentro. Johan sigue con la evidencia, las alternativas y una demo, y al final yo cierro.

ADRI Diapositiva 2 · Una respuesta fluida no es una respuesta verificada ≈ 1:09

Partimos de algo cotidiano: los modelos de lenguaje ya se usan para buscar, redactar y apoyar decisiones, y a veces dicen cosas que suenan perfectas pero son falsas o no se pueden verificar. En el mundo jurídico esto se volvió muy visible, porque hubo abogados sancionados por presentar casos que no existían, inventados por ChatGPT.

La respuesta de la industria fue RAG: que el modelo conteste «a libro abierto», apoyado en documentos recuperados (Lewis et al., 2020). Y varios proveedores llegaron a decir que RAG «elimina» o «evita» las alucinaciones. Por eso ese sello de «A verificar».

De ahí sale nuestra pregunta, y fíjense en el «hasta qué punto»: pide una respuesta graduada, no un sí o un no. La dividimos en cinco subpreguntas: el mecanismo, dónde nace el error, qué dice la evidencia, cómo se mide y qué alternativas hay. Esas cinco son el hilo de la exposición.

> **Ojo:** *Aclarar que las sanciones fueron por casos inventados por ChatGPT, un sistema de propósito general. Las herramientas con RAG son las que Magesh et al. evalúan después.*

ADRI Diapositiva 3 · RAG reduce el riesgo de alucinar; no garantiza veracidad ≈ 1:08

Nuestra tesis en una frase: RAG reduce el riesgo de alucinar, pero no garantiza veracidad. Ayuda con las alucinaciones que vienen de que el modelo no sabe algo o está desactualizado, porque le pone evidencia externa enfrente. Pero lo único que hace es cambiar la distribución de la que se genera la respuesta. No obliga a que cada afirmación salga de esa evidencia.

Para ordenar la lectura planteamos cuatro hipótesis. H1: recuperar reduce la alucinación cuando la evidencia existe y se recupera. H2: aun así queda una fracción de respuestas sin respaldo. H3: ese error que queda no tiene una sola causa, se reparte entre recuperación, uso del contexto, generación y atribución. H4: evaluar la evidencia y verificar afirmaciones reduce más el error, pero a costa de complejidad y latencia.

Son nuestro marco de lectura, no resultados. Las vamos a contrastar con la evidencia en la diapositiva 23.

ADRI Diapositiva 4 · Alucinar es afirmar con apariencia de seguridad lo que nada respalda ≈ 1:10

Antes de seguir, ¿qué es exactamente una alucinación? Depende de la referencia con la que se compare, y la literatura usa tres definiciones. Maynez, en 2020, para resúmenes: es intrínseca si contradice la fuente y extrínseca si agrega algo que no se puede verificar desde la fuente.

Huang, en 2025, para modelos de propósito general, separa factualidad, que es contradecir hechos del mundo, de fidelidad, que es apartarse de las instrucciones o del contexto dado. Y Magesh, en 2025, para sistemas que citan: la respuesta es incorrecta o está mal fundamentada, es decir, cita una fuente que no respalda lo que se afirma.

Lo que tienen en común es que la alucinación es plausible, suena bien, y no tiene respaldo frente a una referencia. Y ojo: no todo error es alucinación. Un error de razonamiento con premisas correctas, o una respuesta que era verdadera cuando el modelo fue entrenado, son otra cosa.

ADRI Diapositiva 5 · Verdadero, fiel y atribuible son tres propiedades distintas

≈ 1:05

De esas definiciones sacamos tres propiedades que hay que mantener separadas. Factualidad: ¿la afirmación es verdadera? Se evalúa contra el mundo o una fuente confiable. Fidelidad: ¿está respaldada por el contexto que le dimos al modelo? Atribución: ¿la fuente que cita realmente respalda esa afirmación?

Un ejemplo de fidelidad, el de la tabla: el documento dice que las mejores imágenes de una ecografía 3D se obtienen entre las semanas 24 y 30, y el modelo responde entre la 20 y la 32. Suena razonable, pero no es fiel al texto.

Esto importa porque RAG actúa directamente sobre la fidelidad, ya que hay un contexto contra el cual comparar, y solo de manera indirecta sobre la factualidad, porque además ese contexto tiene que ser correcto. Una frase puede ser verdadera e infiel, o fiel a un documento equivocado y por eso falsa.

ADRI Diapositiva 6 · RAG ataca la falta de conocimiento, no el objetivo de entrenamiento ≈ 1:07

¿Por qué alucinan los modelos? La tabla recorre seis causas y mira si RAG actúa sobre cada una. En verde, donde sí: el conocimiento limitado en hechos poco frecuentes, siempre que el hecho esté en el corpus y se recupere, y la desactualización, con la condición de que el índice esté al día.

En rojo, donde no actúa directamente: el objetivo de entrenamiento, que premia lo probable y no lo verdadero; la incertidumbre y los incentivos a adivinar en vez de abstenerse (Kalai et al., 2025); y el muestreo aleatorio al decodificar. Las falsedades imitativas y las falsas premisas quedan en amarillo: ayuda solo si el contexto contradice la premisa y el modelo lo aprovecha.

La lectura es que RAG ataca bien lo que tiene que ver con la disponibilidad del conocimiento. Por eso es razonable esperar que reduzca la alucinación, pero no que la elimine.

ADRI Diapositiva 7 · Un LLM calcula qué es probable, no qué es verdadero ≈ 1:11

Ahora tres ecuaciones, solo las necesarias. La primera es la regla de la cadena: la probabilidad de una respuesta completa es el producto de la probabilidad de cada token, dados los anteriores y la entrada. La segunda es la softmax con temperatura, que convierte los puntajes del modelo en probabilidades: con temperatura baja se concentra en lo más probable, con temperatura alta se aplana, y nunca le da probabilidad cero a ningún token. La tercera es la entropía cruzada, que es con lo que se entrena: penaliza dar poca probabilidad a lo que aparece en el corpus.

De ahí salen tres consecuencias. Uno, la probabilidad mide qué tan plausible es algo según lo aprendido, no si es verdad. Dos, ninguna afirmación falsa queda excluida por la arquitectura. Tres, la función de pérdida no tiene ningún término que premie verificar o abstenerse. RAG agrega un contexto z al condicionamiento, pero conserva las tres propiedades.

ADRI Diapositiva 8 · RAG responde «a libro abierto», pero sigue siendo un generador ≈ 1:12

Ahora sí, RAG. Lewis y colegas lo proponen en 2020 combinando dos memorias. La paramétrica son los pesos del modelo: compacta y rápida, pero opaca, difícil de actualizar y con cobertura desigual. La no paramétrica es un corpus externo indexado: se puede editar o reemplazar sin reentrenar y cada fragmento recuperado se puede inspeccionar. En el RAG original eran unos 21 millones de fragmentos de Wikipedia, de 100 palabras cada uno.

Antes de responder se prepara el corpus: se parte en fragmentos, se codifica cada uno como un vector y se indexa para buscar vecinos cercanos. Al consultar se recuperan los k fragmentos más cercanos, ya sea con búsqueda densa, dispersa o híbrida, y opcionalmente con re-ranking.

Lo importante es qué problema resuelve: el acceso al conocimiento, es decir, disponibilidad, actualidad y trazabilidad. Y cada decisión de diseño, como el tamaño del fragmento, el codificador o el valor de k, es una fuente posible de error.

ADRI Diapositiva 9 · Tres ecuaciones explican qué hace RAG, y qué no ≈ 1:02

Estas tres ecuaciones siguen la formulación de Lewis et al. La primera es la puntuación entre consulta y documento: un producto interno entre sus vectores. Mide cercanía temática en el espacio que aprendió el modelo, no implicación lógica ni verdad.

La segunda son los pesos de recuperación: una softmax sobre los k documentos recuperados. Suman uno, así que algún documento siempre recibe un peso alto, aunque ninguno sea relevante.

La tercera es la generación. El documento es una variable oculta y la respuesta es una mezcla: cada documento pesa según su similitud, multiplicada por lo que diría el generador condicionado en ese documento. Un documento irrelevante con peso no despreciable también contribuye a la respuesta. La idea para llevarse: se pondera por similitud, no por si el documento realmente respalda lo que se dice.

ADRI Diapositiva 10 · Recuperar evidencia no obliga a que la respuesta esté respaldada ≈ 1:12

Esta es la diapositiva central. Llamemos S(z) al conjunto de respuestas fielmente respaldadas por los documentos z, o sea, aquellas cuyas afirmaciones se desprenden de z. Es el círculo verde. El modelo, aun con z, puede generar respuestas dentro de ese conjunto y también fuera, los puntos rojos.

Para garantizar respaldo, el sistema tendría que darle probabilidad cero a todo lo que quede fuera de S(z), o restringir la decodificación a S(z). RAG no hace ninguna de las dos. Y como la softmax le da probabilidad positiva a todo, la probabilidad de generar algo fuera de S(z) es mayor que cero. Es la Ecuación 14.

Cuatro consecuencias: con muestreo ninguna respuesta sin respaldo queda excluida; con decodificación determinista nada garantiza que la elegida esté en S(z); la memoria paramétrica sigue activa; y la marginalización pesa por similitud, no por implicación. En una frase: RAG cambia de qué distribución se genera la respuesta, no cuáles respuestas están permitidas.

> **Ojo:** *No decir que alucinar sea probable. Lo que dice la desigualdad es que no es imposible por construcción. Cuánto ocurre es una pregunta empírica, y es lo que sigue.*

ADRI Diapositiva 11 · Tener una fuente no equivale a estar bien fundamentado

≈ 0:50

Una distinción que ordena todo: procesos del sistema contra propiedades de la salida. Recuperación y generación son procesos, el sistema los ejecuta. Grounding, o fidelidad, y atribución son propiedades: la respuesta las tiene o no las tiene.

Un pipeline RAG estándar implementa los procesos, pero no comprueba las propiedades. Recuperar garantiza que el contexto tenga fragmentos parecidos a la consulta, no que contengan la respuesta. Generar garantiza una respuesta fluida, no que use el contexto ni que cada afirmación esté respaldada. Y la cita: que esté presente no prueba que respalde lo afirmado. Una cita es una afirmación más del modelo y se puede alucinar como cualquier otra.

ADRI Diapositiva 12 · El error puede nacer en cinco puntos del pipeline ≈ 1:16

Aquí está el pipeline completo y dónde falla. Va de la consulta al codificador, la búsqueda de los k fragmentos más cercanos, el contexto, el generador y la respuesta con citas, apoyado en el corpus y en los pesos del modelo. Cinco puntos de fallo.

F1, recuperación: la evidencia existe pero no entra entre los k recuperados. F2, contexto: está, pero el ruido la desplaza. F3, fidelidad: la respuesta agrega o contradice lo que dice el contexto. F4, atribución: la cita no respalda la afirmación. F5, brecha de evidencia: lo que se necesita simplemente no está en el corpus.

Abajo está una propuesta nuestra: descomponer el riesgo de alucinar en dos casos, según el contexto tenga o no evidencia suficiente y correcta. P(H) = P(H dado no E) por P(no E), más P(H dado E) por P(E). Mejorar solo el recuperador baja P(no E), pero no toca P(H dado E). Por eso hay que atacar los tres términos, y volvemos a esto en la propuesta.

ADRI Diapositiva 13 · Cada punto de fallo tiene su mecanismo, su ejemplo y su mitigación ≈ 1:03

Esta tabla resume cada fallo con su mecanismo, un ejemplo y qué lo mitiga. F1: la similitud no es relevancia; en el ejemplo jurídico, «error moral» recupera «torpeza moral». F2: ruido, distractores o posición, como una cifra correcta que queda en el fragmento 6 de 10. F3: el contexto condiciona pero no restringe. F4: se cita sin comprobar que la fuente implique la afirmación. F5: el corpus no tiene lo necesario, por ejemplo una guía práctica ante una pregunta de jurisprudencia.

Agregamos una sexta categoría transversal, F6, conflicto y autoridad: fuentes contradictorias, obsoletas o inaplicables, como un precedente revocado presentado como vigente. La taxonomía es elaboración propia, compatible con Barnett, Chen, Niu y Magesh, y el hecho de que clasificaciones hechas con métodos distintos converjan apoya H3: el error no está concentrado en un único componente.

→ **Puente:** *Con esto cerramos la parte conceptual. Johan sigue con lo que muestran los estudios.*

JOHAN Diapositiva 14 · En diálogo, recuperar baja la alucinación de 68,2 % a 7,9–17,0 % ≈ 1:05

Gracias, Adri. Pasamos a la evidencia, empezando por Shuster et al., 2021, en conversación apoyada en Wikipedia. Evaluaron a mano 100 respuestas por modelo. Sin recuperación, el modelo base alucinó en 68,2 % de las respuestas. Con 5 documentos, bajó a 9,6 % con RAG-Sequence, 17,0 % con RAG-Token y 7,9 % con FiD-RAG. Los autores lo resumen como una reducción de más del 60 %.

Dos advertencias. Primera: con 25 documentos en lugar de 5, la alucinación subió, a 21,5 % y 19,8 %. O sea, más contexto no siempre ayuda. Segunda: es un estudio acotado, con 100 respuestas por modelo, anotadores del propio laboratorio, modelos de 2021 y un solo dominio. Respalda H1 y H2, y estas cifras no se pueden comparar con las de otros estudios porque cambian la muestra, la tarea y la definición de alucinación.

JOHAN Diapositiva 15 · Con RAG y corpus autorizados, las herramientas jurídicas aún alucinan ≈ 1:13

Ahora el caso jurídico. Magesh et al., 2025, hicieron la primera evaluación preregistrada de herramientas de investigación jurídica con IA: 202 consultas de derecho estadounidense en cuatro categorías, ejecutadas entre marzo y mayo de 2024, con un acuerdo entre evaluadores de kappa 0,77. Aquí alucinación significa respuesta incorrecta o mal fundamentada.

Resultados: cada herramienta alucinó entre 17 % y 33 % de las consultas, menos que GPT-4. Lexis+ AI dio 65 % de respuestas correctas y fundamentadas. Westlaw AI-Assisted Research, alrededor de 41 %, y alucinó casi el doble que las otras dos herramientas jurídicas. Ask Practical Law AI dio respuestas incompletas en 62 % de los casos, con un corpus más limitado. Y las alucinaciones aparecieron en todas las categorías, incluidas preguntas generales tipo examen de abogacía.

Como referencia, pero sin compararla de forma directa, los modelos de propósito general alucinaron entre 58 % y 82 % en consultas jurídicas en otro estudio (Dahl et al., 2024).

> **Ojo:** *Frase clave: no es «RAG alucina entre 17 % y 33 %». Es lo que estas tres herramientas hicieron en este conjunto de 202 consultas, diseñado para ser desafiante. No es una estimación de la frecuencia real.*

JOHAN Diapositiva 16 · En el caso jurídico, los errores nacen en etapas distintas

≈ 1:13

Magesh también describe de dónde vienen los errores, y son cuatro tipos. Recuperación ingenua: la «doctrina del error moral» trae «torpeza moral», o un juez ficticio trae un caso real de un demandante con apellido parecido. Autoridad inaplicable: cita documentos de otra jurisdicción, de otro tribunal o precedentes revocados.

Complacencia: no corrige una premisa falsa y le agrega información falsa, aunque algunos sistemas sí la corrigieron. Y error de razonamiento: con el pasaje correcto a la vista, le atribuye al tribunal lo que en realidad describía la conducta de la parte demandada.

En el gráfico, el error de razonamiento fue causa contribuyente en 61 % de las respuestas alucinadas de Westlaw, 49 % de Ask Practical Law y 28 % de Lexis+. Las categorías no son excluyentes. El recuadro de abajo es una ilustración conceptual, no un resultado: la cita existe, pero no respalda lo que se afirma. Esto conecta con H3, porque el error aparece en etapas distintas.

JOHAN Diapositiva 17 · Con el contexto delante, persisten afirmaciones y citas sin soporte ≈ 1:22

Dos estudios más. A la izquierda, RAGTruth, de Niu et al.: unas 18.000 respuestas anotadas de seis modelos que responden con un contexto dado. El ejemplo de la diapositiva es el mismo de la ecografía: el pasaje dice semanas 24 a 30 y la respuesta dice 20 a 32, un conflicto evidente con el contexto. Dos hallazgos: la información sin base fue más frecuente que la contradicción directa, y detectar estas alucinaciones es difícil, con F1 de 68,3 % usando un prompt con GPT-4-turbo y 80,7 % con Llama-2-13B ajustado. Por cierto, el 4,8 % de GPT-4 es un cálculo nuestro, 48 de 992 respuestas, a partir del preprint.

A la derecha, atribución. En ALCE, de Gao et al., incluso los mejores modelos tenían soporte incompleto de sus citas en la mitad de las respuestas de ELI5. Y Liu et al. auditaron cuatro motores de búsqueda generativos: solo 51,5 % de las oraciones estaba totalmente respaldada por sus citas, y 74,5 % de las citas respaldaba la oración asociada.

El mensaje: una cita presente no garantiza soporte completo.

> **Ojo:** *Las fuentes y condiciones son distintas, así que no comparar los porcentajes entre sí.*

JOHAN Diapositiva 18 · Los estudios convergen: la recuperación ayuda, ninguno elimina el error ≈ 1:04

Juntemos la evidencia. Shuster y Magesh muestran que recuperar ayuda y que igual queda error. Niu, Gao y Liu muestran fallas de fidelidad y atribución aun con el contexto delante. Min et al. midieron FActScore con evaluación humana en biografías: 42,5 %, 58,3 % y 71,5 % para InstructGPT, ChatGPT y PerplexityAI, que usa búsqueda y tuvo el valor más alto. Y Chen et al. encontraron debilidades en rechazo negativo, integración de información y robustez ante información contrafactual.

La conclusión es que la recuperación reduce la alucinación, ningún estudio la elimina, y el error residual aparece en todas las etapas. Y la conclusión general no es una tasa, es una propiedad: depende del dominio, el corpus, el recuperador, el generador y la tarea, así que hay que medirla en cada sistema. Por eso estos porcentajes no son directamente comparables.

JOHAN Diapositiva 19 · Evaluar RAG exige medir cada dimensión por separado

≈ 1:17

¿Cómo se mide todo esto? Una sola métrica esconde dónde está el error, así que se mide por dimensiones. Recuperación: recall y precision en k, que preguntan si lo recuperado contiene la evidencia necesaria. Relevancia del contexto, fidelidad y relevancia de la respuesta: RAGAS y ARES. Factualidad: FActScore. Calidad de citas: ALCE y Liu et al. Abstención: el benchmark RGB.

A la derecha, tres fórmulas. Recall y precision. La fidelidad de RAGAS, que es la fracción de enunciados de la respuesta que se pueden inferir del contexto. Y FActScore, la proporción media de hechos atómicos respaldados por una fuente; se calcula sobre respuestas donde el modelo no se abstiene, así que también hay que reportar cuántas veces respondió.

Abajo, cuatro limitaciones de la evaluación: depende de la referencia, los evaluadores automáticos también se equivocan, la evaluación humana es cara, y el solapamiento de palabras, como el F1, correlaciona poco con los juicios humanos. Eso explica por qué las cifras de estudios distintos no se pueden comparar.

JOHAN Diapositiva 20 · Las limitaciones son estructurales y el diseño exige compromisos ≈ 1:16

Con eso, las limitaciones. Son siete y son estructurales, no defectos que una versión mejor vaya a quitar: vienen de cómo está definido el mecanismo. La similitud no es relevancia ni verdad. Hay dependencia del corpus. El uso del contexto es imperfecto: posición, ruido y más documentos lo degradan. No hay abstención nativa, el pipeline siempre responde. Los conflictos no tienen regla de resolución: deciden el orden, la redacción y la frecuencia, no la jerarquía. Hay opacidad: en sistemas cerrados solo cabe una auditoría de caja negra. Y la raíz de todo, no hay restricción de fidelidad.

A la derecha, los compromisos de diseño. Más contexto aumenta la probabilidad de incluir la evidencia, pero mete ruido; en Shuster, de 5 a 25 documentos. Subir k mejora el recall pero baja la precisión. Más grounding cuesta fluidez. Más cobertura cuesta latencia, memoria y dinero. Y mejorar la recuperación no cambia P(H dado E). En aplicaciones de alto riesgo, el compromiso se resuelve a favor del grounding.

JOHAN Diapositiva 21 · Cada alternativa interviene en un punto distinto del pipeline ≈ 1:27

Si el error está repartido, la solución no puede ser un único cambio. La investigación posterior propone intervenciones en distintos puntos, y las ordenamos así. Antes de generar está CRAG: un evaluador ligero estima la calidad de lo recuperado y decide si usarlo, buscar en la web o combinar. Ataca F1, F2 y F5 en parte, pero la web añade ruido y no verifica la fidelidad.

Durante la generación están Self-RAG y FLARE. Self-RAG es un solo modelo que decide cuándo recuperar y critica pasajes y respuestas con tokens de reflexión; ataca F2, F3 en parte y F4, pero la autocrítica la hace el mismo modelo y requiere entrenamiento específico. FLARE genera una oración tentativa y recupera si detecta palabras de baja confianza; el límite es que un modelo puede estar equivocado con mucha confianza, y entonces no recupera.

Después de generar están Chain-of-Verification y SelfCheckGPT. En Chain-of-Verification el modelo redacta, plantea preguntas de verificación, las responde de forma independiente y corrige; el verificador sigue siendo el mismo modelo. SelfCheckGPT compara con muestras adicionales, porque lo inventado tiende a divergir; detecta pero no corrige, y no ve alucinaciones consistentes.

> **Ojo:** *Los resultados de cada técnica los reportan sus propios autores en benchmarks concretos. No extrapolar. CRAG es un preprint.*

JOHAN Diapositiva 22 · Ninguna alternativa cubre todos los fallos, y todas cuestan ≈ 0:52

Aquí comparamos todo: dónde interviene cada enfoque, qué fallos reduce, su límite principal y su costo. Hay tres regularidades. Las técnicas se especializan: las que actúan antes de generar atacan sobre todo F1, F2 y F5; las que actúan durante o después, F3 y F4. Ninguna fila cubre todas las categorías de fallo. Y reducir más error se paga en complejidad, latencia o costo humano.

La última fila, verificación de atribución más abstención más revisión humana, es una composición propuesta por nosotros y no ha sido evaluada como sistema. La conclusión de la tabla: RAG es una pieza necesaria pero insuficiente. Resuelve el acceso a la evidencia y deja abierta la verificación.

JOHAN Diapositiva 23 · La mitigación de RAG es condicional, y las hipótesis lo respaldan ≈ 1:24

Volvamos a las hipótesis. H1, H2 y H3 resultan respaldadas. H1 por Shuster, por Magesh, donde las herramientas alucinaron menos que GPT-4, y por Min, con mayor FActScore al usar búsqueda. H2 por Magesh, RAGTruth, ELI5 y Liu. H3 por la tipología de Magesh, las capacidades que evalúa Chen, los puntos de fallo de Barnett y los efectos de posición y ruido. H4 queda solo parcialmente respaldada: las mejoras las reportan los propios autores, y faltan evaluaciones independientes y en alto riesgo.

La tabla de abajo responde la pregunta de investigación de forma graduada. RAG mitiga con fuerza cuando la respuesta está explícita en el corpus, la pregunta es factual y acotada, el contexto es breve y limpio, las citas se verifican y el sistema puede declarar que no sabe. Mitiga poco o falla cuando falta la información, la pregunta exige razonamiento jurídico o técnico, hay ambigüedad o contradicciones, la respuesta es larga o el sistema siempre responde.

Dicho simple: RAG ayuda mucho cuando el problema es de acceso al conocimiento, y poco cuando el problema es de uso fiel de la evidencia.

JOHAN Diapositiva 24 · Propuesta: una capa de control por cada término del riesgo ≈ 1:23

Con todo eso, proponemos una arquitectura por capas: una capa de control por cada término del riesgo. Recuerden la descomposición, P(H) = P(H dado no E) por P(no E), más P(H dado E) por P(E).

Capa 1, evidencia: un corpus curado y versionado, con metadatos de vigencia y autoridad. Reduce F5 y F6. Capa 2, recuperación evaluada: búsqueda híbrida, re-ranking y un evaluador de la calidad de la evidencia. Reduce P(no E), o sea F1 y F2. Capa 3, generación con abstención: instruir o entrenar al modelo para declarar que la evidencia no alcanza. Reduce P(H dado no E). Capa 4, verificación de afirmaciones: cada afirmación se contrasta con su cita usando un verificador independiente del generador. Reduce P(H dado E), es decir F3 y F4. Capa 5, supervisión humana proporcional al riesgo del dominio.

Tiene que quedar claro que esta arquitectura es propuesta nuestra: no está evaluada como sistema integrado, es una síntesis de componentes que sí tienen respaldo parcial por separado. Y ninguna intervención sobre un solo término lleva P(H) a cero mientras los otros sigan siendo positivos.

JOHAN Diapositiva 25 · Un experimento controlado para hacer visible el argumento ≈ 1:31

Para hacer visible el argumento diseñamos un experimento controlado con tres condiciones. A: el modelo sin evidencia, que responde solo con su memoria; es la línea base. B: el modelo con evidencia recuperada de un corpus controlado y con la instrucción de citar. C: lo mismo que B, pero cada afirmación se contrasta con el pasaje que cita; las que no tienen respaldo se marcan o se eliminan, y si no queda soporte, el sistema se abstiene.

Usaríamos un banco de 8 a 12 preguntas en cinco escenarios: evidencia suficiente, insuficiente, donde se espera abstención, distractora, contradictoria, como versión vigente contra derogada, y evidencia al inicio contra el medio del contexto. La unidad de análisis es la afirmación atómica.

Lo que permitiría mostrar, y son expectativas, no resultados: que B respalda más afirmaciones que A cuando la evidencia es suficiente; que B conserva afirmaciones sin respaldo, por distractores, contradicciones o respuestas largas; que sin evidencia B a veces responde en lugar de abstenerse; y que C detecta parte de ese error residual, no todo, y con más latencia. Es trabajo futuro, con valor demostrativo, no inferencial. Y es justo lo que les queremos enseñar ahora en la demo.

> **Ojo:** *Decir siempre que es una propuesta sin resultados. Lo que se vea en la demo no estima tasas ni es evidencia sobre «RAG en general».*

JOHAN DEMO · Johan (después de la diapositiva 25) ≈ 1:58

Johan: Lo que van a ver es una versión pequeña de ese experimento. Vamos a hacerle la misma pregunta al sistema en tres configuraciones: A, sin evidencia; B, con evidencia recuperada; y C, con evidencia y verificación de cada afirmación.

Paso 1, evidencia suficiente. Pregunta: [escribir aquí la pregunta de la demo]. Primero en A: [describir qué responde y si hay datos que no se pueden respaldar]. Ahora en B: fíjense en [qué pasajes recupera y qué cita]. Comparamos cada afirmación con su pasaje. [Señalar qué afirmaciones sí están respaldadas y cuáles no]. Esto conecta con H1 y H2: la evidencia ayuda, y aun así puede quedar una afirmación sin respaldo.

Paso 2, evidencia insuficiente. Pregunta: [pregunta cuya respuesta no esté en el corpus]. Lo que esperamos es que el sistema se abstenga. En B: [qué hizo, si respondió o se abstuvo]. En C: [qué marcó o eliminó el verificador y si se abstuvo]. Esto es la brecha de evidencia, F5, y la capa de abstención de la propuesta.

Paso 3, opcional si da el tiempo: evidencia contradictoria o distractora. [Pregunta y qué se observa]. Es el caso F2 o F6.

Para cerrar la demo: lo que acabamos de ver es demostrativo, no un resultado. Son pocas preguntas, no estimamos tasas y no dice nada sobre RAG en general. Sirve para ver con ojos propios lo que mostraron los estudios: que recuperar ayuda, que queda error, y que verificar detecta parte de ese error, pero con costo. Le devuelvo la palabra a Adri para cerrar.

> **Ojo:** *Los textos entre corchetes dependen de la demo real; completarlos con lo que se vea en pantalla y narrar solo eso. Si en B el sistema alucina, no es un fallo de la demo: es la hipótesis H2. Si C se abstiene, es la capa 3 y 4 funcionando.*

ADRI Diapositiva 26 · RAG mitiga las alucinaciones, pero no es una garantía de veracidad ≈ 1:33

Gracias, Johan. Para cerrar, tres lecturas de lo que vimos. Matemáticamente, RAG agrega un contexto al condicionamiento de un generador que sigue siendo probabilístico: la evidencia orienta la generación, pero no la restringe. Empíricamente, la recuperación reduce la alucinación, a veces de forma sustancial, pero ningún estudio que revisamos la elimina y los errores aparecen en todas las etapas. Conceptualmente, tener una fuente no es lo mismo que estar correctamente fundamentado: eso es una propiedad de cada afirmación frente al texto citado.

Para sistemas reales, la confiabilidad exige cuatro cosas: evaluar la evidencia, verificar afirmaciones, abstenerse cuando corresponda y supervisar en proporción al riesgo. Y tres recomendaciones prácticas: exigirle evidencia específica a quien diga «libre de alucinaciones», incluir el costo de verificar en el cálculo de valor, y evaluar por componentes: recuperación, fidelidad, citas y abstención.

La cadena de abajo resume la idea de todo el trabajo. Una afirmación no vale por sonar bien: necesita evidencia recuperada, contraste documental, verificación y una decisión sobre qué tanta confianza merece. RAG mitiga en la medida en que el problema sea de acceso al conocimiento, y deja de hacerlo cuando el problema es de uso fiel de la evidencia. Muchas gracias. Con gusto recibimos preguntas.

→ **Puente:** *Las diapositivas 27 y 28 son las referencias; déjenlas puestas durante las preguntas.*

Preguntas probables

Respuestas cortas, con quién las contesta. Si la pregunta cae en la parte del otro, se la pasan.

ADRI **¿Entonces RAG no sirve?**

Sí sirve, y los estudios lo muestran: en Shuster la alucinación baja de 68,2 % a 7,9–17,0 %, y las herramientas jurídicas de Magesh alucinaron menos que GPT-4. Lo que decimos es que reduce el riesgo, pero no lo elimina ni lo garantiza, y que sus límites son estructurales.

JOHAN **¿La tasa de alucinación de RAG es 17–33 %?**

No. Es lo que hicieron tres herramientas concretas en un conjunto de 202 consultas diseñado para ser desafiante. No es una estimación de la frecuencia real, y la tasa de un sistema depende del dominio, el corpus, el recuperador, el generador y la tarea.

ADRI **¿Por qué no basta con bajar la temperatura a cero?**

Con decodificación determinista el modelo elige un token por paso, pero nada garantiza que la respuesta resultante esté en el conjunto de respuestas respaldadas por el contexto. Además, la memoria paramétrica sigue activa. La temperatura cambia cómo se elige, no qué está permitido.

JOHAN **¿Su arquitectura por capas funciona?**

No la hemos evaluado como sistema integrado, y lo decimos en la diapositiva. Es una síntesis de componentes que por separado tienen respaldo parcial. El experimento propuesto sería el primer paso para ver qué detecta y a qué costo.